北辰评测方案

本文规定北辰评测的样本准备、结果检查和跨文档核验方式。评测人员应先固定资料和问题，再观察检索证据与回答；仅有接口成功状态不能说明答案正确。

样本与分组

北辰评测方案的版本编号为BC-EVAL-42，正式问题集包含48个案例。案例分为直接查询、跨文档查询、无答案与多轮追问，分别记录各组结果。

样本准备先确认原始资料可以读取，再核对标准答案与原文摘录。原文、问题和标准答案的职责不同，只有原文进入检索知识库。标准答案只提供给评测人员，不能当作待检索文档上传。

直接查询应要求明确事实，例如版本编号或记录期限。跨文档查询需要标注所有必需证据，不能只标一份最容易找到的资料。无答案问题应检查整个固定语料中都没有可确定的答案。

多轮追问应记录完整上下文和最终问题。评测时让系统真实回答前置问题，再执行追问。不同案例使用独立会话，避免上一题的课程名称影响下一题的检索范围。

北辰评测的复查样本比例为25%。复查人员优先核对跨文档遗漏、主体混淆和来源不支持的结论，再抽查其他案例。复查比例不是合格分数，也不是要求召回的文档比例。

结果判定表

本页列出北辰评测的三项观察要求。P95耗时使用成功请求统计，同时报告失败数量；首字是第一个实际回答文本片段，进度事件不计作首字。

检查项	本轮观察目标	说明
请求成功率	100%	所有计划请求均完成
证据全部找齐率	至少90%	适用于有答案案例
总耗时P95	不高于15秒	单独记录冷启动

表中的观察目标仅用于这份虚构方案，不是所有RAG系统的行业标准。若改变问题难度、资料规模或硬件环境，应在报告中说明。不同测试集的数值不能脱离条件直接比较。

证据全部找齐率要求每条必需证据都有对应检索片段。一个问题需要两份资料时，只找到其中一份可以算至少命中一条，但不能算证据全部找齐。指标应当同时报告分母和失败案例。

答案判断先检查事实，再检查事实属于哪个对象。把两门课程的成绩要求互换属于错误，即使输出中同时出现两个正确数值。回答增加了资料没有提供的结论，也需要单独记录。

北辰评测报告保留期为210天。报告保存问题版本、原文版本和实际回答，复核表记录评分人员及理由。图像证据应保存关联原图，不能仅保留一段脱离图像的摘要。

吞吐量观察图

下图比较三个演练组在同一观察窗口内的吞吐量。具体数值仅在图中给出。读取时先核对组名和纵向含义，再回答对应组的数值。

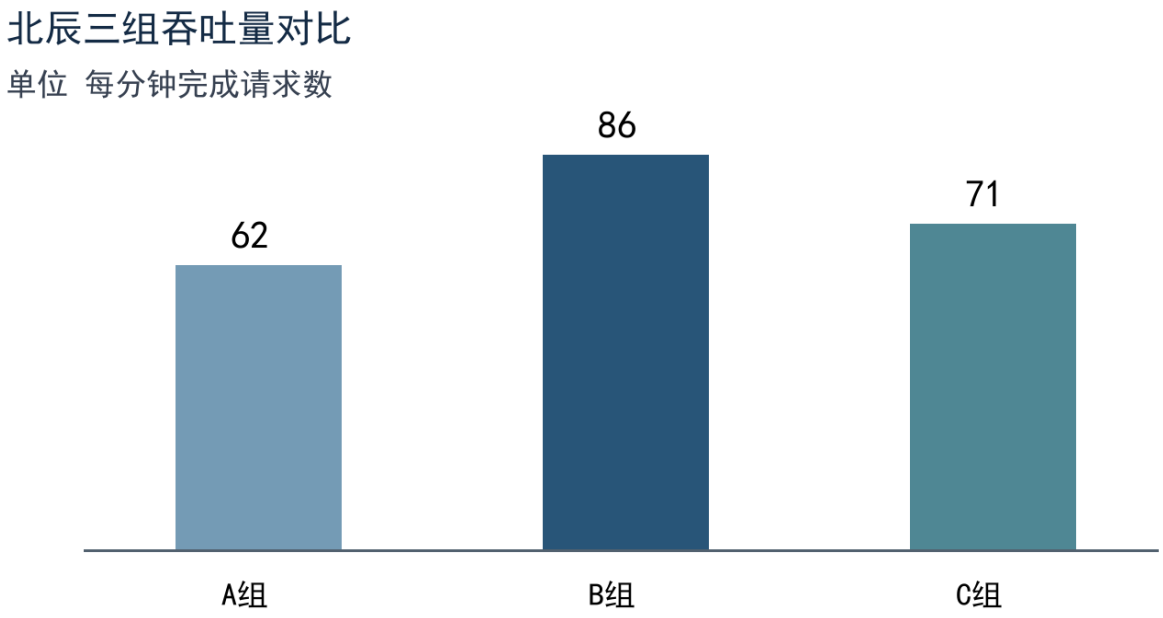


图1 北辰三组吞吐量对比

图像证据复核

图像理解结果需要与原图关联。若本轮未开启视觉理解，可记录图像已归档，但不能宣称已验证图内数值。图像题应单独统计，避免影响纯文本问题的比较。

图片中的组名与正文中的案例类别不同。不能把A组直接解释为直接查询组，也不能把B组解释为跨文档组；图中只给出演练组标签，没有提供这种映射关系。

本文未提供北辰评测服务的访问口令、登录网址或负责人电话。遇到相应问题，应说明资料不足，不能根据版本编号或文件名推断凭据。